

1. Título del Proyecto.

Generación automática de resúmenes en lenguaje sencillo en salud

2. Organización/Grupo de investigación.

Estudiantes de maestría en inteligencia artificial - MAIA. perteneciente al **Departamento de Ingeniería de Sistemas y Computación de la Universidad de los Andes**.

Este grupo centra sus esfuerzos en el desarrollo y aplicación de tecnologías de información y comunicación para resolver problemáticas sociales y científicas.

Experto asociado:

- **Rubén Manrique**, profesor del Departamento de Ingeniería de Sistemas y Computación en la Universidad de los Andes. Doctor en Ingeniería Informática, con experiencia en el diseño y evaluación de modelos de inteligencia artificial aplicados al procesamiento de lenguaje natural.

3. Contexto, problema y Justificación. Impacto esperado.

La alfabetización en salud entendida como la capacidad de comprender y utilizar información relacionada con la salud sigue siendo un desafío a nivel global. Estudios reportan que cerca de la mitad de la población adulta en Europa presenta niveles inadecuados de alfabetización en salud, lo cual impacta negativamente en el seguimiento de tratamientos, la comprensión de instrucciones médicas y la toma de decisiones informadas. Este problema se acentúa en poblaciones vulnerables como adultos mayores o personas con bajo nivel educativo.

Los resúmenes en lenguaje sencillo (Plain Language Summaries, PLS) se han identificado como una estrategia efectiva para hacer accesible la información biomédica y clínica, pero su elaboración manual es lenta, costosa y poco escalable.

Aunque los grandes modelos de lenguaje (LLMs) han mostrado un potencial prometedor para generar automáticamente resúmenes en lenguaje sencillo, la investigación actual presenta vacíos importantes:

- Falta de clasificadores robustos para diferenciar entre lenguaje técnico y lenguaje accesible.
- Escasez de datasets curados y adecuados para el entrenamiento de modelos en este dominio.
- Limitada evaluación sistemática que combine métricas de relevancia semántica, factualidad y legibilidad.

Lo anterior limita la aplicabilidad de los modelos generativos en contextos de salud y plantea la necesidad de metodologías más confiables y evaluaciones más rigurosas.

El proyecto pretende fortalecer la alfabetización en salud mediante el diseño de herramientas automáticas que generen resúmenes comprensibles para pacientes, familiares y público en general. Entre los beneficios esperados se destacan:

- Mejora de la equidad en salud: facilitando el acceso a información clara a personas con diferentes niveles educativos y socioeconómicos.
- Optimización de procesos clínicos y de investigación: al disponer de resúmenes rápidos y accesibles que puedan complementar la comunicación médico-paciente.
- Aplicaciones potenciales: plataformas digitales de salud, repositorios científicos abiertos, guías de práctica clínica y campañas de divulgación en salud pública.

4. Objetivos

Objetivo general

Desarrollar y evaluar un sistema de procesamiento de lenguaje natural clasificando texto técnico y sencillo, así como la generación automática resúmenes en lenguaje sencillo a partir de textos clínicos y científicos en salud, utilizando modelos de lenguaje de menos de 3 mil millones de parámetros, con el fin de contribuir a la mejora de la alfabetización en salud y facilitar el acceso a información comprensible y de calidad.

Objetivos específicos

1. Entrenar clasificadores que distingan lenguaje técnico y lenguaje sencillo en textos biomédicos, empleando representaciones contextuales y dispersas.
2. Adaptar modelos de lenguaje tipo *decoder* de pequeña y mediana escala (<3B de parámetros) para la generación de resúmenes en lenguaje sencillo, aplicando técnicas de fine-tuning y estrategias de Chain of Thought (CoT) que potencien la capacidad de razonamiento y la coherencia explicativa, evaluando su desempeño en términos de relevancia, factualidad y legibilidad.
3. Comparar el rendimiento de modelos ajustados (<3B) con grandes modelos comerciales accesibles vía API (>10B de parámetros), estableciendo ventajas, limitaciones y escenarios de uso en la generación de resúmenes en salud.
4. Implementar un prototipo de despliegue del sistema desarrollado, integrando los clasificadores y modelos de generación en una herramienta accesible para su uso en contextos de salud, explorando casos de aplicación como plataformas digitales, repositorios de investigación o materiales de divulgación.
5. Evaluar las metodologías propuestas mediante la integración de métricas objetivas y el uso de los clasificadores desarrollados, formulando conclusiones sobre la idoneidad de los modelos y la aplicabilidad de los resultados en entornos reales.

5. Estado del arte

Arias-Russi, et al., 2025, en el artículo **Bridging the Gap in Health Literacy: Harnessing the Power of Large Language Models to Generate Plain Language Summaries from Biomedical Texts**, aborda el problema de la baja alfabetización en salud, los autores proponen el uso de resúmenes en lenguaje sencillo (Plain Language Summaries, PLS) como herramienta de traducción de textos biomédicos técnicos a versiones comprensibles para audiencias no expertas, para esto se probaron diferentes modelos de lenguaje de gran escala (LLMs) como GPT-3.5, GPT-4, Gemini 1.5, DeepSeek-R1 y Llama-3.2. Los resultados muestran que los modelos API(no locales) generaron resúmenes más legibles y adecuados, mientras que los modelos ejecutados localmente produjeron textos más técnicos.

En el artículo **Large Language Models for Biomedical Text Simplification: Promising but Not There**, Li, et. al (2024), exploran el uso de modelos de lenguaje de gran escala (LLMs) para

la tarea de simplificación de textos biomédicos, con el fin de mejorar la alfabetización en salud, los autores experimentan con diferentes enfoques, como Modelos encoder–decoder, Modelos decoder-only, Mecanismos de control con tokens, Técnicas de ajuste eficiente como LoRA, cuya evaluación combina métricas automáticas (BLEU, ROUGE, SARI y BERTScore) y juicios humanos, el trabajo concluye que los LLMs muestran un gran potencial para la simplificación biomédica, pero aún enfrentan limitaciones como pérdida de información, dificultades en el manejo de abreviaturas médicas y variabilidad en la evaluación humana.

Guo, et al., 2025, en el artículo **Are LLM-generated plain language summaries truly understandable? A large-scale crowdsourced evaluation**, investigan si los modelos de lenguaje de gran escala (LLMs) generan resúmenes en lenguaje claro (PLSs) realmente comprensibles para audiencias no expertas. Aunque los PLSs son fundamentales para mejorar la comunicación médico-paciente, la mayoría de evaluaciones previas han utilizado métricas automáticas (BLEU, ROUGE, etc.) o juicios subjetivos, sin medir de manera directa la comprensión. En los resultados, subjetivamente, los participantes valoraron los PLSs generados por LLMs como comparables a los humanos pero, objetivamente, los resúmenes humanos produjeron mejor comprensión (mayor precisión en preguntas de opción múltiple). Los LLMs, pese a mayor fluidez y legibilidad, no lograron transmitir la información con igual claridad. El estudio evidencia una brecha entre la **percepción de calidad** y la **comprensión real** de los PLSs generados por LLMs

En el artículo **Adapting Biomedical Abstracts into Plain language using Large Language Models** Gangavarapu, et al., 2025, abordan la necesidad de adaptar resúmenes biomédicos a lenguaje claro (Plain Language Adaptation, PLA). Se evaluaron distintos LLMs open-source y comerciales mediante dos enfoques el primero realizando Fine-tuning eficiente (PEFT/LoRA) sobre LLaMa-2 (13B y 70B chat) y T5-Large; el segundo aplicado In-context learning (ICL) sobre GPT-3.5 y GPT-4, incorporando ejemplos y guías de anotación del dataset PLABA. El estudio demuestra que los LLMs, especialmente GPT-4 con prompts basados en guías de anotación, superan a modelos fine-tuned en la tarea de simplificación biomédica, produciendo resúmenes más comprensibles y fieles al contenido original.

6. Metodología y enfoque propuesto

La solución propuesta enfoca la metodología en el uso de técnicas avanzadas de procesamiento de lenguaje natural (PLN) basadas en modelos de lenguaje de distinta escala, con el fin de generar automáticamente resúmenes en lenguaje sencillo (Plain Language Summaries, PLS) a partir de textos clínicos técnicos.

El proyecto contempla dos operaciones principales:

6.1. Clasificación de lenguaje técnico vs. lenguaje sencillo

Se entrenarán clasificadores binarios de tal forma que puedan identificar si un texto corresponde a lenguaje técnico o sencillo, para ello, se explorarán representaciones dispersas, utilizando principalmente TF-IDF y contextuales mediante embeddings de BERT (Devlin et al., 2019).

6.2. Generación automática de resúmenes en lenguaje sencillo

Se utilizarán 4 modelos de lenguaje tipo decoder de pequeña y mediana escala (<3B de parámetros): LLaMA-3.2-3B (Meta), BioMedLM-2.7B (Stanford, entrenado en PubMed), BART-406M(Facebook), Gemma-2B (Google DeepMind).

Estos modelos serán optimizados mediante LoRA (Hu et al., 2021) como técnica principal de fine-tuning.

Se aplicará además Instruction Tuning(Wei et al., 2022) en conjunto con LoRA para alinear los modelos a la tarea de generación de PLS en salud. Adicionalmente, se explorará el uso de Chain-of-Thought prompting basándonos en las recomendaciones de estudios previos (Arias-Russi, Salazar-Lara, & Manrique, 2025), una técnica que guía a los modelos a razonar paso a paso antes de producir la salida final, lo que ha demostrado mejorar el desempeño en tareas complejas de comprensión y generación de texto


En paralelo, se evaluarán 4 modelos comerciales vía API (>10B parámetros): GPT-5 (OpenAI), gemini-2.5-pro (Google), grok-4(xAI) y claude-sonnet-4(Antrophic).

Fases metodología de desarrollo

La metodología se organizará en fases iterativas:

- Exploración de datos y preparación de los datos.
- Entrenamiento de los modelos clasificadores.
- Generación de texto PLS basados en el texto científico.
- Fine-tuning de modelos resúmenes.
- Evaluación y comparación: análisis del desempeño de clasificadores y generadores de resúmenes en sus métricas respectivas.
- Integración en prototipo: desarrollo de un API para exponer los dos modelos y un interfaz gráfica para un acceso de prueba rápido al API.

Diagrama de la solución



Herramientas

Durante el desarrollo del proyecto se hará uso de las siguientes herramientas:

- Lenguajes de programación: Python
- Librerías: PyTorch, Scikit-learn.
- Plataformas y recursos: Hugging Face, Google Colab, Github, APIs de LLMs comerciales
- Prototipo: Streamlit, FastAPI.

7. Exploración y descripción de los datos

El conjunto de datos se encuentra en construcción, se han tomado como base los datos publicados en la investigación "Bridging the Gap in Health Literacy: Harnessing the Power of Large Language Models to Generate Plain Language Summaries from Biomedical Texts" (Arias-Russi, Salazar-Lara, Manrique, 2025), cuyo objetivo es evaluar métodos de PLN para identificar lenguaje sencillo (PLS) y medir el desempeño de LLMs (GPT-3.5/GPT-4) para generar resúmenes en lenguaje claro a partir de textos biomédicos. Algunos de los principales desafíos detectados se relacionan con la cobertura y el equilibrio del corpus, dado que la distribución por subdominios biomédicos puede estar desbalanceada, por ejemplo, entre ensayos clínicos y guías. Otro reto es la frontera entre textos PLS y no-PLS, ya que la distinción entre lo "sencillo" y lo "técnico" depende en gran medida del contexto; este aspecto se abordará mediante criterios consistentes de etiquetado y validación cruzada. Finalmente, se identifican problemas de calidad y duplicados, con posibles redundancias entre fuentes y versiones de un mismo texto, que serán controlados a través de la detección de duplicados y la aplicación de bloqueos entre los distintos splits.

En cuanto a la decisión sobre fuentes adicionales y datos artificiales, realizaremos pruebas tempranas para responder dos preguntas clave: si la señal del corpus actual es suficiente para separar PLS de no-PLS y si la cobertura temática e idiomática limita el desempeño. Con base en esos resultados, se optará por ampliar las fuentes (incorporando datasets equivalentes con licencias compatibles y priorizando los subdominios e idiomas deficitarios) o, de ser necesario, por generar datos sintéticos únicamente para balancear clases o cubrir vacíos. En todos los casos, los datos sintéticos se etiquetarán explícitamente como tales y quedarán excluidos del conjunto de pruebas.

Preparación de Datos

Para asegurar una representación textual óptima que impulse el rendimiento de los modelos, se implementará un riguroso pipeline de preparación de datos, cuya finalidad principal es garantizar la calidad, trazabilidad y utilidad del corpus para las tareas de clasificación y generación de texto. El proceso comenzará con un inventario detallado de las fuentes, registrando licencias y metadatos clave como dominio, año y procedencia para asegurar una trazabilidad completa. A continuación, se ejecutará una fase intensiva de control de calidad, aplicando procesos de normalización para estandarizar la codificación de caracteres, unificar espacios y eliminar artefactos de texto, con la precaución de preservar siglas y unidades biomédicas esenciales para el contexto clínico. Se utilizarán técnicas como shingling y medición de similitud para detectar y gestionar duplicados o casi-duplicados, asegurando que no haya solapamiento entre los conjuntos de entrenamiento, validación y prueba. Además, se realizará una auditoría de la longitud de los documentos y la densidad terminológica para marcar y analizar valores atípicos que puedan afectar el entrenamiento.

El preprocesamiento lingüístico se adaptará a la complejidad de cada modelo, explorando una tokenización clásica como Bag-of-Words con ponderación TF-IDF para los modelos base y para las arquitecturas neuronales se emplearán métodos de subpalabra como WordPiece o SentencePiece, que capturan mejor la morfología del lenguaje técnico. La eliminación de palabras vacías (stopwords) se evaluará empíricamente, comparando listas genéricas (NLTK, SpaCy) con vocabularios adaptados al dominio médico. De igual forma, se comparará el rendimiento de la lematización frente al stemming, seleccionando el enfoque que conserve los matices clínicos más relevantes.

Finalmente, se enriquecerá la representación de los datos mediante la ingeniería de características y el uso de embeddings. Se calcularán rasgos de legibilidad (índice de Flesch, longitud de oraciones) y se integrarán señales informativas provenientes de análisis previos. Se explorará el uso de embeddings estáticos como Word2Vec y contextuales, específicamente variantes de BERT pre-entrenadas en español o en dominios biomédicos, para capturar con mayor fidelidad las relaciones semánticas del texto. Estos vectores, junto con la importancia de variables extraídas de modelos preliminares, guiarán una selección de características robusta y fundamentada.

8. Consideraciones éticas

En el desarrollo de este proyecto se asume un compromiso ético con el uso responsable de los datos y la tecnología aplicada en salud. El set de datos a utilizar ya se encuentra anonimizado y será manejado bajo la confidencialidad pertinente con el objetivo de no incluir datos sensibles de pacientes. De esta manera se garantiza el cumplimiento de los principios de confidencialidad, privacidad y respeto por los derechos de las personas, en concordancia con las normativas internacionales de protección de datos.

Asimismo, se buscará asegurar la transparencia y la trazabilidad en la construcción de los modelos, documentando de manera clara las decisiones metodológicas y técnicas. Esto incluye registrar las métricas empleadas para evaluar los clasificadores y modelos generadores, así como los criterios de comparación con modelos comerciales, con el fin de minimizar sesgos y garantizar la reproducibilidad de los resultados.

Finalmente, se prestará especial atención a la responsabilidad social que implica la generación automática de resúmenes en salud. Con el asesoramiento del experto en el tema, se solicitarán y adoptarán prácticas de validación para revisar la veracidad y la legibilidad de los textos generados, reduciendo el riesgo de difundir información errónea o incompleta que pueda afectar la toma de decisiones en contextos clínicos.

Por último, el proyecto se concibe como una herramienta de apoyo, no como sustituto de la orientación médica profesional, contribuyendo de manera ética a la mejora de la alfabetización en salud.

9. Evaluación y métricas

Las métricas utilizadas para los modelos serán las siguientes:

Para los modelos asociados a la tarea Clasificación de lenguaje técnico vs. sencillo se utilizarán las métricas Accuracy, Precision, Recall, F1-score.

Para los modelos asociados a la generación de texto sencillo, incluyendo menores a 3B parámetros y comerciales superiores a 10B, se utilizarán las métricas de Relevancia (Zhang et al., 2020), Factualidad (Zha et al., 2023) y Legibilidad (Flesch, 1948; Coleman & Liao, 1975; Gunning, 1952; Chall & Dale, 1995).

La evaluación de los modelos se realizará de la siguiente forma:

El mejor clasificador entrenado será utilizado para analizar los resúmenes producidos por los distintos modelos decodificadores

Se evaluará el rendimiento generando resúmenes de los modelos inferiores a 3B parámetros, tanto en su versión base como después del fine-tuning, frente a los modelos de mayor tamaño 10B (APIs comerciales), empleando como criterios las métricas relevancia, factualidad y legibilidad.

El estudio de Arias-Russi, Salazar-Lara y Manrique (2025) presenta un marco para generar resúmenes en lenguaje sencillo (PLS) a partir de textos biomédicos. Se desarrolló un clasificador de lenguaje técnico vs. sencillo que alcanzó una exactitud del 97.5%, mostrando alta precisión y buena generalización. Posteriormente, se evaluaron modelos de lenguaje a gran escala. Los modelos API (GPT-4, GPT-4o, Gemini) produjeron textos más legibles y reconocidos como PLS, aunque con factualidad ligeramente menor. En contraste, los modelos locales (Llama-3.2, DeepSeek-R1) mantuvieron mayor fidelidad factual, pero generaron resúmenes más técnicos. En la evaluación cualitativa, GPT-4 superó a GPT-3.5 en exactitud, legibilidad, completitud y utilidad, consolidándose como la opción más robusta para generar resúmenes claros y útiles. En conjunto, la integración de un clasificador confiable con modelos avanzados constituye una estrategia efectiva para mejorar la accesibilidad de la información biomédica.

9. Cronograma de actividades

La Tabla 1 presenta el cronograma de actividades para el desarrollo del proyecto. Este cronograma organiza de manera secuencial las fases principales del trabajo, desde la preparación de los datos hasta el despliegue del prototipo y la redacción del artículo. Las actividades se distribuyen a lo largo de siete semanas, siguiendo una metodología iterativa que integra el ciclo de vida de los datos y las etapas de desarrollo de modelos de lenguaje.

Tabla 1. Cronograma de actividades — Proyecto: Generación automática de resúmenes en lenguaje sencillo							
Actividades	Semana 1	Semana 2	Semana 3	Semana 4	Semana 5	Semana 6	Semana 7
Preparación y limpieza de datos							
Entrenamiento de clasificadores (técnico vs sencillo)							
Entrenamiento y fine-tuning de modelos generadores (<3B)							
Comparación con modelos comerciales (>10B)							
Desarrollo de la API (FastAPI)							
Despliegue y pruebas del prototipo (Streamlit + API)							
Evaluación final de clasificadores y resúmenes							
Visualización de resultados y validación							
Redacción del artículo final							
Presentación final							

11. Bibliografía

Arias-Russi, F., Salazar-Lara, C., & Manrique, R. (2025). Bridging the gap in health literacy: Harnessing the power of large language models to generate plain language summaries from biomedical texts. In *Proceedings of the Second Workshop on Patient-Oriented Language Processing (CL4Health)* (pp. 269–284). Association for Computational Linguistics. <https://aclanthology.org/2025.cl4health-1.23/>

Coleman, M., & Liao, T. L. (1975). A computer readability formula designed for machine scoring. *Journal of Applied Psychology*, 60(2), 283–284. <https://doi.org/10.1037/h0076540>

Chall, J. S., & Dale, E. (1995). *Readability revisited: The new Dale–Chall readability formula*. Brookline Books.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT* (pp. 4171–4186). Association for Computational Linguistics. <https://doi.org/10.48550/arXiv.1810.04805>

Flesch, R. (1948). A new readability yardstick. *Journal of Applied Psychology*, 32(3), 221–233. <https://doi.org/10.1037/h0057532>

Gangavarapu, H., Ramachandran, G. K., Lybarger, K., Yetisgen, M., & Uzuner, Ö. (2025). Adapting biomedical abstracts into plain language using large language models. *arXiv preprint arXiv:2501.15700*. <https://arxiv.org/abs/2501.15700>

Gunning, R. (1952). *The technique of clear writing*. McGraw–Hill.

Guo, Y., Sohn, J. H., Leroy, G., & Cohen, T. (2025). Are LLM-generated plain language summaries truly understandable? A large-scale crowdsourced evaluation. *arXiv preprint arXiv:2505.10409*. <https://arxiv.org/abs/2505.10409>

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, L., ... & Chen, W. (2021). LoRA: Low-rank adaptation of large language models.. <https://doi.org/10.48550/arXiv.2106.09685>

Li, Z., Belkadi, S., Micheletti, N., Han, L., Shardlow, M., & Nenadic, G. (2024). Large language models for biomedical text simplification: Promising but not there yet. *arXiv preprint arXiv:2408.03871*. <https://arxiv.org/abs/2408.03871>

Wei, J., Tay, Y., Bommasani, R., Zoph, B., Colwell, L., Wang, S., ... & Le, Q. (2022). Finetuned language models are zero-shot learners. <https://doi.org/10.48550/arXiv.2109.01652>

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., ... Zhou, D. (2022). Chain-of-Thought prompting elicits reasoning in large language models. *arXiv preprint*. <https://doi.org/10.48550/arXiv.2201.11903>

Zha, Y., Yang, Y., Li, R., & Hu, Z. (2023). AlignScore: Evaluating factual consistency with a unified alignment function. *arXiv preprint*. <https://doi.org/10.48550/arXiv.2305.16739>

Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations (ICLR 2020)*. <https://openreview.net/forum?id=SkeHuCVFDr>