

Generación automática de resúmenes en lenguaje sencillo en salud

Juan Ordoñez-Acuña^{1,2}, Hainer Torrenegra-Jimenez^{1,2}, Alejandra Rojas-Garzon^{1,2}, Brayan Gomez Salamanca^{1,2}

¹Universidad de los Andes, ²Departamento de Ingeniería de Sistemas y Computación

{js.ordoneza1, h.torrenegra, m.rojas19, b.gomezs}@uniandes.edu.co

Resumen

La alfabetización en salud (*Health Literacy*), definida como la capacidad de comprender, evaluar y utilizar información relacionada con la salud, persiste como un desafío significativo a nivel global, impactando negativamente el seguimiento de tratamientos y la toma de decisiones informadas. Este artículo presenta un sistema computacional diseñado para (i) clasificar textos biomédicos en lenguaje científico o lenguaje sencillo (*Plain Language Summary* - PLS) y (ii) generar PLS a partir de textos técnicos. La generación se realiza mediante modelos de lenguaje grandes (LLMs) de código abierto y tamaño reducido (inferiores a 3 mil millones de parámetros), ajustados con QLoRA e incorporando estrategias de razonamiento (*Chain-of-Thought zero-shoot* - CoT), con un enfoque en la viabilidad técnica en ambientes de **hardware limitado**. La evaluación combina métricas de relevancia (BERTScore), factualidad (AlignScore) y legibilidad (Flesch y afines). Los resultados evidencian que el ajuste fino mejora de manera consistente el desempeño de los modelos pequeños, aunque con impactos diferenciados según la métrica. Tras el entrenamiento, estos modelos se vuelven competitivos en factualidad y relevancia, aproximándose al comportamiento de modelos de mayor escala. Sin embargo, persiste una brecha significativa en legibilidad frente a los modelos API, especialmente en métricas como CLI, GFI y FKGL. Asimismo, los experimentos muestran que el rendimiento de los modelos ligeros es altamente sensible a la formulación del *prompt*, tanto bajo *Prompt Optimizado* como bajo razonamiento implícito (*Chain-of-Thought*), lo que subraya la importancia de estrategias cuidadosas de ingeniería de *prompts* para maximizar su eficacia.

1. Introducción

Los resúmenes en lenguaje sencillo (*Plain Language Summary* - PLS) facilitan la comprensión de

evidencia biomédica por parte de pacientes y público general. Sin embargo la producción manual de estos resúmenes es un proceso costoso, lento y no escalable.

El presente artículo aborda una comparación exhaustiva entre los grandes modelos de lenguaje grandes (LLMs) comerciales, y modelos pequeños (inferiores a 3 mil millones de parámetros) Se evalúa el desempeño de estos últimos mediante *fine-tuning* eficiente (QLoRA) e incorpora técnicas de *prompting* incluyendo el **razonamiento tipo zero-shoot** (*Chain-of-Thought*, CoT), propuesto por Kojima et al. (Kojima et al., 2022). Adicionalmente se propone un pipeline escalable y ejecutable en **hardware de recursos limitados** con el fin de democratizar el acceso a estas soluciones en entornos que carecen de alta capacidad de cómputo.

Por ello se construyó un *pipeline* metodológico de dos etapas: La primera etapa consiste en la clasificación de textos (PLS vs. científico), donde evaluamos clasificadores con enfoques dispersos y contextuales. La segunda etapa se enfoca en la generación de PLS a partir de texto técnico con modelos inferiores a 3 mil millones de parámetros) ajustados mediante *Quantization and Low-Rank Adaptation* (QLoRA). La evaluación del sistema se basa en una batería de métricas que cubren la relevancia (BERTScore), factualidad (AlignScore), legibilidad (Flesch, Flesch-Kincaid, Coleman-Liau, Dale-Chall, Gunning Fog).

2. Estado del arte

Los *plain language summaries* (PLS) han sido propuestos como puente fundamental para la alfabetización en salud, al traducir contenidos biomédicos técnicos a versiones comprensibles para audiencias no expertas. En esta línea, (Arias-Russi et al., 2025), evaluaron esta hipótesis comparando *large language models* (LLMs) accesibles por API (p. ej., GPT-3.5, GPT-4, Gemini 1.5, DeepSeek-R1)

y modelos ejecutados localmente (p. ej., Llama 3.2). Los resultados indican que los modelos por API tienden a producir resúmenes más legibles y adecuados al público general, mientras que los modelos locales conservan un sesgo hacia formulaciones más técnicas.

Un hito fundamental en el desarrollo de modelos de lenguaje a gran escala fue el trabajo de Brown et al. (Brown et al., 2020), quienes introdujeron GPT-3 y demostraron que un modelo con cientos de miles de millones de parámetros puede ejecutar múltiples tareas mediante *few-shot learning*, reduciendo la necesidad de ajustes específicos o grandes conjuntos de datos anotados. Este resultado redefinió el paradigma de generalización en modelos generativos y sentó las bases para técnicas posteriores de ajuste eficiente como LoRA y QLoRA.

De forma complementaria, (Li et al., 2024) estudió la simplificación biomédica con LLMs y reportó que, aunque estos modelos son prometedores, persisten desafíos significativos como la pérdida de información, el manejo deficiente de abreviaturas y la alta variabilidad en la evaluación humana. Su trabajo contrasta arquitecturas y tácticas (encoder-decoder, *decoder-only*, control mediante *prompt* y *tokens*, y ajuste eficiente con LoRA), usando métricas automáticas (BLEU, ROUGE, SARI, BERTScore) y juicios humanos. Concluyen que es indispensable la integración de control explícito y criterios de evaluación más robustos para mejorar la utilidad clínica de los PLS generados.

Más recientemente, (Guo et al., 2025) cuestionó la efectividad de los PLS generados por LLMs en términos de comprensión real para audiencias no expertas. En una evaluación a gran escala con participantes, identificaron una brecha entre percepción y comprensión: aunque los PLS generados por LLMs fueron subjetivamente valorados como comparables a los resúmenes producidos por humanos, objetivamente los resúmenes humanos condujeron a un mayor acierto en preguntas de opción múltiple. Esto subraya que la legibilidad y fluidez no garantizan comprensión efectiva del contenido.

Por último, (Gangavarapu et al., 2025) abordó la adaptación de resúmenes biomédicos a lenguaje claro (PLA) con dos enfoques: (i) *fine-tuning* eficiente (PEFT/LoRA) sobre LLaMA-2 (13B, 70B) y T5-Large; y (ii) *in-context learning* (ICL) con GPT-3.5 y GPT-4, integrando ejemplos y guías de anotación del conjunto PLABA. Los resultados muestran que GPT-4, con *prompts* basados en guías de anotación, supera a modelos *fine-tuned* en com-

presibilidad y fidelidad al contenido, destacando la importancia de la ingeniería de *prompts* y del uso de pautas de anotación para alinear estilo y factualidad.

3. Metodología

3.1. Recolección de los Datos

En la fase de recolección de datos se construyó el conjunto de entrenamiento y evaluación tomando como base las fuentes publicadas en (Arias-Russi et al., 2025). Específicamente, se empleó el corpus COCHRANE, estructurado en dos categorías principales:

- **Textos científicos (non-PLS):** artículos y reportes biomédicos en lenguaje técnico.
- **Resúmenes en lenguaje sencillo (PLS):** versiones simplificadas de los textos científicos, destinadas a una audiencia general.

Los archivos fuente originales fueron distribuidos en directorios separados para entrenamiento y prueba (train/test), con subdirectorios por clase (pls y non_pls).

Durante la etapa inicial de recopilación y análisis, se identificaron dos limitaciones prácticas que influyeron en la selección final del conjunto de datos. Primero, las restricciones de licencia de algunos repositorios biomédicos ampliamente utilizados, como COCHRANE, impiden el uso directo de artículos nuevos para el entrenamiento de modelos de IA en contextos académicos. Segundo, la **escala y complejidad computacional** de repositorios públicos alternativos (e.g., BIOLAYSUMM (bio)), que exceden los 30,000 registros con longitudes de texto superiores a los 10,000 tokens en muchos casos, Esta escala incrementa significativamente el consumo de GPU y memoria VRAM volviendo inviable el *fine-tuning* eficiente en entornos de recursos limitados.

Por estas razones, se decidió emplear el conjunto de datos disponible en (Arias-Russi et al., 2025), ya que ofrece un equilibrio entre calidad, la accesibilidad computacional y el tamaño de los datos, además permite la realización del *fine-tuning* de modelos de tamaño pequeño de manera eficiente con los recursos limitados.

3.2. Proceso de preparación

El proceso de preprocesamiento se centró en consolidar múltiples archivos de texto (.txt) en un

formato estructurado y etiquetado, adecuado para el entrenamiento y evaluación de los modelos.

Normalización y carga (Clasificación) Para la tarea de clasificación (PLS vs. Científico) se implementó la función `convertir_txt_data_frame`, que itera sobre los directorios del corpus y aplica una normalización ligera durante la lectura de cada archivo. Las operaciones realizadas incluyen:

- **Codificación y tolerancia a fallos:** se utilizó codificación UTF-8 con omisión de errores de lectura (`errors="ignore"`).
- **Limpieza básica:** recorte de espacios iniciales y finales con el método `.strip()`.
- **Etiquetado binario:** asignación de etiqueta 1 para textos **PLS** y 0 para textos **científicos (non-PLS)**.
- **Consolidación:** concatenación de los conjuntos `train/test` de ambas clases en un único *DataFrame* de pandas.
- **Persistencia:** el *DataFrame* consolidado se guardó en fragmentos de 15,000 filas para facilitar manejo y versionamiento en el repositorio del código.

Emparejamiento PLS/Non-PLS (Generación) En paralelo, para el análisis exploratorio y la subsiguiente tarea de generación de resúmenes, se desarrolló la función `convertir_txt_data_frame_test` con el fin de **emparejar** cada texto científico con su correspondiente PLS de origen. Este proceso de alineación se detalla a continuación:

- **Extracción de identificadores:** Se generó un identificador común a partir de los nombres de archivo (p.ej., eliminando sufijos como `-abstract` o `-pls`).
- **Alineación:** Mediante dicho identificador, se realizó una operación de `merge` entre los *DataFrames* para alinear cada **article** (texto científico) con su **summary** (PLS).
- **Conjunto final:** El resultado se almacenó como `cochrane_total`, donde cada fila contiene el **par alineado** (`article`, `summary`), insumo fundamental para el *fine-tuning* de los modelos generativos. Este conjunto se dividió en subconjuntos de entrenamiento, validación y prueba `{data_finetuning_}train, test, val`, de 3038, 380 y 380 registros respectivamente.




Figura 1: Comparación de longitudes (número de palabras) entre textos **científicos** y **PLS**.

3.3. Estadísticas exploratorias (EDA)

El Análisis Exploratorio de Datos (EDA) inicial se enfocó en cuantificar los documentos y analizar sus distribuciones de longitud y el nivel de complejidad textual, que son variables clave tanto para la clasificación como para la generación de PLS.

Conteo de documentos El conteo total de archivos de texto cargados desde el corpus Cochrane, previo a la consolidación y particionado, fue el siguiente:

- **Entrenamiento (científico / non-PLS):** 31 118
- **Entrenamiento (PLS):** 16 241
- **Prueba (científico / non-PLS):** 7 664
- **Prueba (PLS):** 3 940

Análisis de longitud Se realizó un análisis comparativo de la *longitud* (número de palabras) entre las dos clases de textos. Como se ilustra en los histogramas (Fig. 1), existe una diferencia de distribución *muy marcada* entre ambas clases.

Los textos **científicos** muestran una distribución de longitud considerablemente más amplia, con una media mayor y una cola larga que indica la presencia de documentos muy extensos (superando frecuentemente las 2 000 palabras). En contraste, los **resúmenes PLS** son significativamente más cortos y muestran una distribución más acotada y consistente, agrupándose la mayoría por debajo de las 500 palabras.

Análisis de complejidad La complejidad textual se reporta mediante `text_standard`, una métrica *consenso* que agrega varios índices clásicos de legibilidad para devolver un **Índice estimado** en términos de grado de escolaridad requerido. `Text_standard` combina: Flesch Reading Ease (Flesch, 1948), Flesch–Kincaid Grade (Kincaid et al., 1975), Coleman–Liau (Coleman and Liau, 1975), Dale–Chall (Chall and Dale, 1995), Gunning Fog (Gunning, 1952), y el Automated Readability Index (ARI) (Smith and Senter, 1967) y SMOG (McLaughlin, 1969). La tabla 1 resume la interpretación práctica de este índice.

En la Fig. 2 se observan **distribuciones amplias y solapadas**: si bien los textos **científicos** concentran mayor densidad en la zona media, los **PLS** muestran un ligero desplazamiento hacia grados de complejidad mayores. Ello implica que, en este corpus, la complejidad es elevada en ambas clases; la mayoría de los textos se encuentran en el rango superior a 12, categorizándolos como *lectura académica*. (La media de `text_standard` para los artículos científicos es 13,89 y para PLS es 14,23).

Análisis de legibilidad El índice *Flesch Reading Ease* (FRE) estima la **facilidad de lectura** en una escala de 0–100 donde **valores mayores indican textos más fáciles** (Flesch, 1948) a partir de la longitud media de las oraciones y el promedio de sílabas por palabra.

En la Fig. 3 se observan **distribuciones solapadas**, con la clase **PLS** *ligeramente desplazada hacia valores más altos* (aprox. 40–45) respecto a la clase **científica** (aprox. 30–35). Esto sugiere que, en este corpus, los **resúmenes PLS** tienden a ser *marginalmente más fáciles de leer* según FRE. Como guía práctica, puntuaciones FRE $\gtrsim 60$ suelen asociarse a lectura “entendible”, mientras que valores $\lesssim 30$ denotan textos difíciles (La FRE media para los artículos científicos es 32.98 y para




Figura 2: Comparación del índice de complejidad agregado entre textos **científicos** y **PLS**.

PLS 35.97) lo cual evidencia que la gran mayoría de los textos en ambas clases, incluidos los PLS de referencia, se encuentran en el rango de lectura Difícil o Muy Difícil. El corpus base de "Lenguaje Sencillo.es", en realidad, de complejidad académica. La tabla 2 agrupa en porcentajes de complejidad el los corpus pertenecientes al texto científico y PLS utilizado para el ejercicio de fine-tuning.

3.4. Clasificador (técnico vs. PLS)

Para la tarea de clasificación binaria (texto científico vs. PLS), Se abordaron dos aproximaciones distintas: un modelo disperso basado en representaciones *Term Frequency-Inverse Document Frequency* (TF-IDF) y un modelo contextual basado en incrustaciones (*embeddings*) de *Transformers*. Ambos modelos fueron entrenados y evaluados sobre el mismo conjunto de datos (divididos en entrenamiento, pruebas y validación).

Enfoque Disperso (TF-IDF) Se implementó un *pipeline* que combinó la vectorización TF-IDF con una búsqueda de hiperparámetros mediante GridSearchCV. El texto fue normalizado previamente con un pre-procesador personalizado (TextPreprocessor) que incluyó limpieza ligera y tokenización controlada. Se exploró el desempeño

Tabla 1: Guía de interpretación del índice agregado: grado estimado y nivel de escolaridad.

Rango	Grado Años	Nivel Educativo
4–6	4.º–6.º	Lectura muy sencilla
7–9	7.º–9.º	Lectura sencilla
10–12	10.º–12.º	Lectura estándar
13–16	Universidad	Lectura académica
≥ 17	Posgrado	Lectura técnica

	Extremadamente Difícil (< 10)	Muy Difícil (10–30)	Difícil (30–50)	Ligeramente Difícil (50–60)	Estándar (>60)
Científico	1.6 %	34.5 %	60.5 %	3.3 %	0.2 %
PLS	0.9 %	26.8 %	63.6 %	7.7 %	1.0 %

Tabla 2: Distribución porcentual de categorías de legibilidad (Flesch Reading Ease) en artículos científicos y resúmenes PLS.




Figura 3: Comparación del índice de legibilidad entre textos **científicos** y **PLS** .

de múltiples algoritmos de aprendizaje supervisado, incluyendo: RidgeClassifier, SGDClassifier, PassiveAggressiveClassifier, LinearSVC, Perceptron, LogisticRegression, RandomForest, ComplementNB y MultinomialNB. La evaluación de este enfoque se basó en las métricas estándar: *Accuracy*, *Precision*, *Recall* y F_1 -score.

Enfoque Contextual (Transformer) Se empleó un modelo contextual de tipo *Transformer* , concretamente google/electra-small-discriminator (14 M de parámetros) (Clark et al., 2020). Se utilizó el tokenizador del modelo y se diseñó un *pipeline* adaptado para textos largos que segmenta en ventanas de hasta 512 tokens; sobre la representación se definió una cabeza ligera para **clasificación binaria**. El entrenamiento se realizó por épocas usando *dataloaders* de tamaño fijo. ELECTRA entrena con un objetivo de *replaced token detection*, más eficiente que el enmascarado de BERT (Devlin et al., 2019); en la evaluación de (Clark et al., 2020) se muestra que ELECTRA-Small logra resultados comparables a BERT-Base en GLUE (Wang et al., 2019) con una fracción del costo computacional.

3.5. Generación de PLS y configuración de entrenamiento

La generación de resúmenes en lenguaje claro se abordó mediante un **pipeline**, diseñado para adaptar distintos modelos de lenguaje de propósito general a la tarea biomédica de generar resúmenes en lenguaje sencillo. El objetivo fue evaluar el desempeño de diferentes arquitecturas de tipo *decoder-*

only en la generación de textos comprensibles y factuales.

Modelos utilizados. El pipeline fue aplicado a cuatro modelos base de código abierto todos con un tamaño de parámetros reducido, buscando la viabilidad del despliegue local:

- **Gemma-3-1B-PT** (Google DeepMind),
- **LLaMA 3.2-1B** (Meta),
- **deepseek-coder-1.3b-base** (DeepSeek),
- **Qwen3-1.7B** (Alibaba Cloud).

Todos estos modelos comparten una arquitectura *decoder-only*, lo cual permitió reutilizar la misma lógica de ajuste fino, tokenización e inferencia. Adicionalmente, se realizaron inferencias comparativas con modelos de gran escala (**GPT-5**, **Claude**, **Grok** y **Gemini**) empleando los mismos *prompts* de entrada, con el fin de establecer un punto de referencia superior de desempeño.

Datos y preprocesamiento. Para garantizar la comparabilidad se utilizó el mismo conjunto de datos alineado (par artículo/resumen PLS), dividido en subconjuntos de entrenamiento, validación y prueba {*data_finetuning_*}*train*,*test*,*val* descrito en la Subsección 3.2.

El preprocesamiento se implementó en Python utilizando una estrategia de *chunking* de secuencias de hasta 4096 tokens y superposición de 128 tokens para conservar la coherencia contextual en artículos extensos.

Iteraciones experimentales El proceso contempló dos iteraciones de generación y evaluación diferenciadas por la estrategia de *prompting* empleada:

- **Primera iteración (prompt base):** En esta fase se utilizó un *prompt* estándar mencionado en (Arias-Russi et al., 2025), aplicado de forma idéntica tanto a los modelos pequeños con y sin ajuste fino (Gemma, LLaMA, DeepSeek, Qwen) como a los modelos grandes de referencia (GPT-5, Claude, Grok y Gemini). Este *prompt* corresponde al mensaje de sistema descrito en la Sección A.1
- **Segunda iteración Prompt Optimizado vs CoT implícito:** Con el fin de explorar mejoras en las métricas, se introdujo un *prompt* con **razonamiento tipo zero-shoot** (Chain-of-Thought, CoT), técnica propuesta por Kojima

et al. (Kojima et al., 2022), que induce al modelo a reflexionar brevemente antes de responder sin mostrar el razonamiento al usuario final. Esta estrategia, descrita en la sección A.3, se compara con un *prompt* optimizado (A.2) diseñado para modelos de lenguaje pequeños, con menor cantidad de tokens e instrucciones simplificadas para reducir la confusión del modelo e intentar mejorar el rendimiento.

Aproximaciones de entrenamiento. Con el fin de evaluar la flexibilidad del pipeline en distintos entornos computacionales, se implementaron dos aproximaciones de entrenamiento que reflejan escenarios de recursos variados. En la primera aproximación, los modelos **Gemma-3-1B-PT** y **LLaMA 3.2-1B** fueron entrenados en la nube mediante **Google Colab Pro+** utilizando una GPU **NVIDIA L4 (22 GB de VRAM)**. Esta configuración permitió aplicar un esquema de entrenamiento más intensivo y no realizar chunking (opcional en el código), con un mayor tamaño de lote efectivo, acumulación de gradientes y *early stopping*, siguiendo el código optimizado para entornos de alta capacidad. En la segunda aproximación, los modelos **Qwen3-1.7B** y **DeepSeek** se entrenaron en un entorno **local** con una GPU **NVIDIA RTX 4050 (6 GB de VRAM)**. Para este entorno de recursos limitados, se adoptaron configuraciones optimizadas, que incluyeron el uso de *chunking* para la segmentación de los textos de entrada, la reducción de la longitud máxima de secuencia, un tamaño de lote unitario y la acumulación de gradientes cada 16 pasos. Estas medidas permitieron ejecutar el entrenamiento de manera estable y eficiente dentro de las restricciones de memoria disponibles. La comparación de ambos enfoques demostró la **portabilidad y escalabilidad** del pipeline propuesto, que permite realizar ajustes finos reproducibles y comparables tanto en entornos locales de bajo costo como en plataformas en la nube de gama media/alta.

Arquitectura y configuración de entrenamiento y Ajuste fino El *pipeline* de ajuste fino utilizó el framework Transformers de Hugging Face, en conjunto con PEFT (*Parameter-Efficient Fine-Tuning*) para implementar la técnica **QLoRA** (*Quantization and Low-Rank Adaptation*) (Dettmers et al., 2023). Cada modelo se cargó con cuantización de 4 bits mediante la librería BitsAndBytes (nf4) y cómputo en precisión mixta (bf16/fp16). Específicamente, el ajuste QLoRA se aplicó sobre los módulos clave de atención (q_proj, k_proj,

v_proj, o_proj). El código fuente detallado de estos entrenamientos se encuentra disponible en el repositorio ¹

3.6. Métricas de evaluación y criterios

La evaluación del desempeño de los modelos se realizó mediante un conjunto de métricas complementarias que permiten comparar la calidad de los resúmenes generados por los distintos modelos desde tres dimensiones fundamentales: **relevancia semántica**, **legibilidad** y **factualidad**. Estas métricas fueron seleccionadas para capturar de manera integral la calidad de los *Plain Language Summaries* (PLS) generados, combinando medidas automáticas de similitud textual, comprensión lectora y exactitud factual.

3.6.1. Relevancia semántica.

La relevancia se midió con la métrica **BERTScore** (Zhang et al., 2020), calculada sobre los pares de texto generado y referencia. Se utilizó como modelo base roberta-large, con configuración de inferencia en modo contextualizado e incorporación de pesos por IDF. De cada modelo se obtuvieron las medidas promedio de *precisión*, *recall* y *F1* (mean_precision, mean_recall, mean_f1). Estos valores reflejan el grado de solapamiento semántico entre el contenido generado y el de referencia. Valores altos de F1 indican que el modelo conserva la mayor parte del contenido relevante del texto original, manteniendo coherencia semántica en el lenguaje claro.

3.6.2. Legibilidad.

La legibilidad de los resúmenes se evaluó mediante indicadores clásicos de comprensión lectora aplicados a lengua inglesa: **Flesch Reading Ease (FRE)** (Flesch, 1948), **Flesch-Kincaid Grade Level (FKGL)** (Kincaid et al., 1975), **Coleman-Liau Index** (Coleman and Liau, 1975), **Dale-Chall** (Chall and Dale, 1995), **Gunning Fog** (Gunning, 1952), y **SMOG Index** (McLaughlin, 1969). Estas métricas fueron calculadas con la librería textstat, tomando en cuenta el número de palabras, sílabas, oraciones y longitud promedio de las frases. En particular, el *Flesch Reading Ease* asigna valores más altos a textos fáciles de leer (p. ej. >60 corresponde a un nivel de lectura accesible para público general), mientras que el *Flesch-Kincaid*

¹<https://github.com/SebastianOrd/Proyecto-PLN-FLAG/tree/main>

Grade estima el grado escolar requerido para comprender el texto. De esta manera, se buscó cuantificar la capacidad de los modelos para transformar lenguaje técnico en formulaciones accesibles.

3.6.3. Factualidad.

La factualidad se midió con la métrica **AlignScore** (Zha et al., 2023), la cual esta basada en modelos de inferencia textual (*Natural Language Inference*, *NLI*) que determinan el grado de consistencia entre el resumen generado y el texto original.

En este trabajo se utilizaron los modos de evaluación *nli_sp* y *bin_sp*. El modo *nli_sp* genera un puntaje continuo de consistencia factual, mientras que *bin_sp* clasifica cada afirmación como respaldada o no respaldada por el texto fuente, permitiendo un análisis complementario en escala binaria.

Se calcularon las estadísticas *mean_alignscore*, *std_alignscore*, *min_alignscore* y *max_alignscore* para cada uno de los dos métodos de evaluación sobre el conjunto de validación. Valores más altos de *AlignScore* indican mayor fidelidad factual del resumen con respecto a la evidencia original, lo cual resulta crítico en el dominio biomédico.

En el presente artículo, solo se presentan los valores consolidados de las métricas principales (como *BERTScore F₁*, *AlignScore Binary* y *Flesch Reading Ease*) para la discusión de los resultados. El detalle completo de los resultados de todas las métricas de legibilidad y factualidad, así como la trazabilidad de los datos de evaluación, se encuentra disponible para su consulta en el repositorio del código fuente del proyecto ².

4. Resultados

4.1. Clasificación

El análisis de la tarea de clasificación binaria (texto científico vs. PLS) se abordó mediante el contraste de dos enfoques metodológicos.

Los mejores resultados para el clasificador de enfoque *disperso* se obtuvieron con el algoritmo **RidgeClassifier** (Pedregosa et al., 2011), tras un *grid search* exhaustivo, configurado con *solver* = *sag* y $\alpha = 0,5$, alcanzando una **exactitud** de **0,9992** en el conjunto de prueba. Este desempeño refleja alta estabilidad y consistencia en validación cruzada, sugiere que las representaciones **TF-IDF** capturan de manera efectiva diferencias léxicas y

²<https://github.com/SebastianOrd/Proyecto-PLN-FLAG/tree/main>




Figura 4: Matriz de confusión **Clasificador disperso**.

terminológicas entre textos científicos y resúmenes en lenguaje sencillo (Salton and Buckley, 1988). Las métricas por clase (precisión, *recall* y F1) para este modelo se detallan en la **Tabla 3**. La matriz de confusión correspondiente se ilustra en la Fig. 4.

Por su parte, el modelo *contextual*, basado en **ELECTRA Small Discriminator** (Clark et al., 2020), alcanzó una **exactitud** de **0,9985**. Si bien este valor resultó ser marginalmente inferior al obtenido por el enfoque disperso, su rendimiento fue igualmente sobresaliente. Las métricas por clase correspondientes se presentan en la **Tabla 4**, y la matriz de confusión se muestra en la Fig. 5. La alta precisión observada en ambos modelos confirma la robustez y la clara separabilidad inherente entre las clases de documentos analizadas en este corpus.

En términos de costo temporal y operacional, el modelo **disperso** basado en **RidgeClassifier** mostró tiempos de *entrenamiento* e *inferencia* considerablemente menores, lo que permitió ejecutar lotes amplios de textos con rapidez y bajo consumo de recursos. En contraste, el modelo **contextual** (ELECTRA Small) debido a su arquitectura *Transformer* presentó tiempos mas elevados. Esta brecha

Tabla 3: Métricas por clase — **RidgeClassifier** (disperso).

Métrica	Clase 0 (No-PLS)	Clase 1 (PLS)
precision	0.9997	0.9983
recall	0.9991	0.9993
f1-score	0.9994	0.9988




Figura 5: Matriz de confusión **Clasificador contextual**.

operacional resalta la **eficiencia** del enfoque disperso para tareas de *clasificación binaria* en escenarios de alto volumen y recursos limitados.

4.2. Generación PLS

Resultados primera iteración Para evaluar de forma consistente el comportamiento de los modelos, se ejecutó la inferencia sobre 380 artículos del conjunto de prueba. Tras generar los resúmenes correspondientes, se calcularon las distintas métricas de calidad textual definidas en la Subsección 3.5. A continuación, se detallan los resultados obtenidos en las dos iteraciones experimentales.

La **Tabla 5** presenta los valores promedio de las métricas de relevancia, factualidad y legibilidad para los cuatro modelos pequeños sin ningún ajuste vs ajustados mediante QLoRA y vs cuatro modelos de gran escala (*API-based*) utilizados como referencia, todos evaluados con el *prompt* base A.1.

Resultados segunda iteración La segunda iteración evaluó el impacto de utilizar el razonamiento implícito (*Chain-of-Thought zero-shot*, CoT) A.3 y un *prompt* optimizado (*OPT*) A.2 en el rendimiento de los modelos pequeños. Los resultados se resu-

Tabla 4: Métricas por clase — **Modelo contextual (ELECTRA Small)**.

Métrica	Clase 0 (No PLS)	Clase 1 (PLS)
precision	0.9998	0.9961
recall	0.9979	0.9979
f1-score	0.9989	0.9979




Figura 6: Comparación resultados con los resúmenes de expertos para la métrica Text Standard

men en la **Tabla 6**. Los resultados de la segunda iteración confirman la **sensibilidad del rendimiento de los LLMs pequeños al *prompt* de entrada**, un hallazgo clave de esta investigación.

5. Discusión

La interpretación conjunta de los resultados de clasificación y generación evidencia que, si bien el enfoque propuesto permite automatizar la producción de resúmenes en lenguaje sencillo (PLS) a partir de literatura biomédica, la **legibilidad de los PLS generados** persiste como una limitación. Los modelos ajustados localmente no alcanzan los niveles requeridos para el público general, lo que sugiere que, en su estado actual, el sistema es funcional pero aún insuficiente para garantizar PLS plenamente accesibles.

El análisis del corpus de entrenamiento proporciona el contexto fundamental para esta limitación como se observa en la Fig.6 y en la Fig.7 los datos de referencia clasificados como PLS en el corpus de Cochrane tienen una **complejidad textual intrínseca elevada**. Las métricas de legibilidad (FRE media de 35,97 y FKGL media de 14,23) demuestran que la mayoría de los textos de "lenguaje sencillo" se encuentran, de hecho, en el rango de *lectura académica* ($\gtrsim 90\%$ clasificados como Difícil o Muy Difícil). Esta **alta complejidad del *target* de entrenamiento** explica directamente por qué los modelos locales, a pesar de sus mejoras, no logran producir resúmenes con legibilidad de nivel estándar o sencillo (FRE $\gtrsim 60$) para el público general.

El desempeño de los modelos ligeros ajustados mediante QLoRA se alinea con la tendencia reciente de investigación que enfatiza la eficiencia en arquitecturas de pequeña escala (Kojima et al., 2022). En este estudio, la incorporación de *Chain-*

Model	Readability						Factuality		Relevance
	CLI↓	FRE↑	GFI↓	SMOG↓	FKGL↓	DCRS↓	AS _{NLI} ↑	AS _{BIN} ↑	BERTScore↑
DeepSeek_base	14.42	49.56	11.28	12.69	10.49	10.27	0.40	0.68	0.828
Gemma3_base	15.50	44.79	12.21	<u>13.38</u>	11.32	<u>10.81</u>	0.48	0.68	0.837
Llama3.2_base	<u>21.30</u>	<u>26.17</u>	<u>12.39</u>	13.27	<u>13.89</u>	10.27	0.45	0.53	0.841
Qwen3_base	15.01	48.73	11.28	13.27	10.97	9.11	0.51	0.69	0.836
DeepSeek _{FT}	13.98	53.31	10.28	11.99	9.84	8.95	0.44	0.54	0.836
Gemma3 _{FT}	14.36	53.41	10.36	11.83	9.88	9.53	<u>0.38</u>	<u>0.44</u>	0.814
Llama3.2 _{FT}	13.98	54.95	10.86	11.83	9.83	9.51	<u>0.43</u>	<u>0.47</u>	0.822
Qwen3 _{FT}	13.23	54.83	10.50	11.98	9.77	9.03	0.45	0.46	0.831
Claude_API	9.37	84.08	5.03	7.39	4.21	6.47	0.51	0.61	<u>0.811</u>
Gemini_API	7.75	89.07	4.68	6.64	3.35	6.27	0.51	0.55	<u>0.813</u>
GPT5_API	9.49	81.92	6.50	7.98	5.25	7.33	0.62	0.66	0.820
Grok_API	7.84	89.74	4.27	6.31	2.99	7.10	0.43	0.50	0.815

Tabla 5: Comparación cuantitativa entre modelos con en el conjunto de pruebas. Los mejores valores se muestran en **negrita** y los peores en subrayado.

Model	Readability						Factuality		Relevance
	CLI↓	FRE↑	GFI↓	SMOG↓	FKGL↓	DCRS↓	AS _{NLI} ↑	AS _{BIN} ↑	BERTScore↑
DeepSeek_OPT	12.80	56.92	9.75	11.68	9.17	8.91	<u>0.45</u>	0.65	0.848
Gemma3_OPT	14.03	50.97	10.37	12.38	10.22	9.26	0.47	0.69	0.856
Llama3.2_OPT	13.88	51.66	10.63	12.50	10.31	9.09	0.47	<u>0.47</u>	0.858
Qwen3_OPT	13.59	54.16	9.62	12.01	9.61	8.67	0.47	<u>0.69</u>	0.851
DeepSeek_COT	12.93	56.20	10.17	11.81	9.49	8.78	0.46	0.62	0.850
Gemma3_COT	<u>14.08</u>	<u>50.27</u>	<u>11.18</u>	<u>12.67</u>	<u>10.53</u>	<u>9.66</u>	0.49	0.67	0.854
Llama3.2_COT	13.28	55.03	10.25	12.08	<u>9.63</u>	<u>8.98</u>	0.53	0.69	0.856
Qwen3_COT	13.23	56.16	9.69	11.85	9.35	8.61	0.50	0.52	0.858

Tabla 6: Resultados cuantitativos para el conjunto de pruebas bajo el enfoque *Chain-of-Thought zero-shoot* y *Prompt optimizado*. Los mejores valores aparecen en **negrita**, mientras que los peores se indican con subrayado.




Figura 7: Comparación resultados con los resúmenes de expertos para la métrica FRE

of-Thought zero-shot (CoT) produjo mejoras apreciables tanto en la **factualidad** (e.g., L

5.1. Fortalezas del enfoque

Clasificación: Una primera fortaleza es la **alta separabilidad entre textos científicos y PLS**, demostrada por los clasificadores dispersos y contextuales, con exactitudes superiores al 99.8 %. Esto confirma que los textos del corpus presentan diferencias estructurales claras, lo que facilita la detec-

ción automática y garantiza una etapa de filtrado confiable para el pipeline completo.

Generación de PLS: El uso de modelos ligeros ajustados con QLoRA mostró ser **computacionalmente eficiente**, permitiendo ejecutar experimentos incluso en hardware limitado como una GPU de 6 GB. El pipeline diseñado fue portable y reproducible, logrando mantener coherencia en los experimentos tanto en la nube (L4) como en entornos locales.

Asimismo, la combinación de **prompts optimizados y razonamiento zero-shot (CoT)** mejoró consistentemente la factualidad y, en algunos casos, la relevancia semántica y la legibilidad. Este resultado subraya la sensibilidad de los modelos pequeños al diseño del *prompt*, evidenciando que estrategias de razonamiento controlado refuerzan la coherencia y reducen errores de omisión, un hallazgo clave de la investigación.

Finalmente, la integración simultánea de métricas de **legibilidad, factualidad y relevancia** permitió realizar una evaluación más amplia que la que ofrecen medidas tradicionales como BLEU o

ROUGE.

5.2. Debilidades y limitaciones

A pesar de estas fortalezas, el enfoque presenta debilidades claras. En primer lugar, los modelos pequeños producen PLS con una **legibilidad inferior** a los modelos de referencia API, incluso después de ajustes específicos del *prompting* y del razonamiento CoT. Esta brecha en la accesibilidad se debe, fundamentalmente, a la **alta complejidad intrínseca del corpus de entrenamiento**: como lo demostró el EDA, los PLS de referencia poseen una complejidad de *lectura académica* (e.g., FKGL promedio de 14,23), con más del 90 % clasificado como Difícil o Muy Difícil (Tabla 2). Por lo tanto, el modelo ajustado replica un estilo de simplificación que aún utiliza **estructuras sintácticas densas y terminología técnica**, limitando su aplicabilidad en entornos reales de comunicación con pacientes sin formación especializada.

En segundo lugar, aunque el CoT zero-shot mejora la consistencia y la factualidad (e.g., AS_{BIN} de Llama 3.2_COT alcanzó 0,53) en la evaluación nli, también se observó una tendencia a **incrementar la complejidad textual** en algunos casos, elevando métricas como FKGL, SMOG y Gunning Fog.

Finalmente, el estudio se apoya exclusivamente en métricas automáticas, las cuales no capturan la **comprensión real de usuarios humanos**. Como señalan trabajos recientes (Guo et al., 2025), la calidad percibida y la utilidad práctica de los PLS dependen de factores cognitivos y contextuales que trascienden la evaluación automática, por lo que resulta necesario incorporar validaciones con lectores reales en estudios posteriores.

5.3. Reflexión general

En conjunto, los resultados muestran que el enfoque es **viable, eficiente y prometedor**, especialmente en escenarios donde se requiere operar con recursos computacionales limitados. Los modelos pequeños finetuneados logran acercarse al rendimiento de alternativas comerciales en factualidad y relevancia, pero aún presentan brechas importantes en legibilidad y estabilidad frente a cambios en el *prompt*.

La metodología desarrollada que combina ajuste fino eficiente, razonamiento implícito y evaluación multidimensional, lo que constituye una base sólida para futuras investigaciones. Sin embargo, para que el sistema sea realmente útil en aplicaciones clínicas o educativas, será necesario avanzar hacia:

(i) corpus más estandarizados, (ii) mecanismos adicionales de simplificación o post-procesamiento, y (iii) validaciones con usuarios reales que permitan evaluar su impacto en la comprensión y toma de decisiones de pacientes y cuidadores.

6. Conclusiones y trabajo futuro

Este trabajo presentó un *pipeline* integral para la clasificación y generación de resúmenes en lenguaje sencillo (PLS) a partir de textos biomédicos. El sistema combina modelos ligeros ajustados con QLoRA, técnicas de *prompting* y un conjunto multidimensional de métricas orientadas a legibilidad, factualidad y relevancia. Los resultados demostraron que es posible obtener un rendimiento competitivo incluso con modelos locales de bajo costo computacional, siempre que se empleen estrategias adecuadas de ajuste fino y mecanismos de razonamiento controlado.

Datos Un hallazgo relevante del proyecto fue la identificación de recursos adicionales, como BIO-LAYSUMM, que podrían reforzar el entrenamiento de modelos para generación de PLS. Sin embargo, su escala y longitud promedio representan un desafío en entornos con recursos limitados. Esto evidencia la necesidad futura de explorar técnicas de muestreo, reducción de secuencias y preprocesamiento avanzado para aprovechar corpus extensos sin comprometer la viabilidad técnica del entrenamiento.

Clasificación El enfoque híbrido entre representaciones dispersas (TF-IDF) y modelos contextuales (ELECTRA Small) alcanzó exactitudes superiores al 99.8 %, confirmando la clara separabilidad entre textos científicos y PLS. Este resultado subraya que, para tareas binarias con diferencias marcadas de complejidad textual, los modelos dispersos siguen siendo una alternativa eficiente, interpretable y escalable, especialmente cuando los recursos computacionales son limitados.

Generación En términos de generación, los modelos comerciales por API produjeron resúmenes altamente legibles, aunque con tendencia a simplificar en exceso el contenido. Por contraste, los modelos pequeños ajustados localmente preservaron mayor densidad informativa y lograron un mejor equilibrio entre fidelidad factual y relevancia semántica. El uso de *Chain-of-Thought zero-shot* y *prompts* optimizados demostró ser clave para mejorar la coherencia y factualidad sin incrementar

de forma desproporcionada la complejidad textual, confirmando el potencial de estas técnicas para potenciar modelos ligeros.

Futuro El trabajo deja abiertas varias líneas de investigación. Entre ellas destacan: incorporar evaluación humana sistemática para validar comprensión real más allá de métricas automáticas; explorar modelos encoder–decoder especializados en simplificación biomédica; ampliar el corpus con fuentes multilingües; y profundizar en técnicas avanzadas de razonamiento controlado (p. ej., *self-consistency*, *critique-and-rewrite*). Asimismo, integrar verificadores automáticos de soporte factual podría reducir aún más errores de interpretación en dominios sensibles como la salud.

Una línea particularmente prometedora consiste en explorar arquitecturas de tipo *Mixture of Experts* (MoE). Modelos recientes, como el presentado en (Zhang et al., 2025), demuestran que los MoE pueden alcanzar un rendimiento comparable —e incluso superior— al de modelos densos de gran escala, manteniendo costos de entrenamiento e inferencia considerablemente menores. Este enfoque sería especialmente útil para la generación de PLS, ya que permitiría combinar expertos especializados en simplificación léxica, control de estilo, preservación factual y estructuración del contenido, sin incrementar de manera sustancial los requerimientos computacionales. La capacidad de los MoE para activar solo un subconjunto de expertos por instancia abre la posibilidad de obtener modelos más eficientes, modulables y adaptados a las distintas sub-tareas que exige la generación de lenguaje claro.

Referencias

- Biolaysumm. <https://biolaysumm.org/#data>. Accessed: 2025-11-19.
- Felipe Arias-Russi, Carolina Salazar-Lara, and Ricardo Manrique. 2025. Bridging the gap in health literacy: Harnessing the power of large language models to generate plain language summaries from biomedical texts. Manuscript in preparation.
- Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, and 12 others. 2020. [Language models are few-shot learners](#). *arXiv preprint arXiv:2005.14165*.
- Jeanne S. Chall and Edgar Dale. 1995. *Readability Revisited: The New Dale–Chall Readability Formula*. Brookline Books, Cambridge, MA, USA.
- Kevin Clark, Minh-Thang Luong, Quoc V. Le, and Christopher D. Manning. 2020. [Electra: Pre-training text encoders as discriminators rather than generators](#). In *Proceedings of the International Conference on Learning Representations (ICLR)*.
- Meri Coleman and T. L. Liao. 1975. A computer readability formula designed for machine scoring. *Journal of Applied Psychology*, 60(2):283–284.
- Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. 2023. [Qlora: Efficient finetuning of quantized large language models](#). *arXiv preprint arXiv:2305.14314*.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pages 4171–4186.
- Rudolf Flesch. 1948. A new readability yardstick. *Journal of Applied Psychology*, 32(3):221–233.
- Harsha Gangavarapu and 1 others. 2025. Adapting biomedical abstracts into plain language using large language models. Preprint.
- Robert Gunning. 1952. *The Technique of Clear Writing*. McGraw–Hill, New York, NY, USA.
- Yifan Guo and 1 others. 2025. Are llm-generated plain language summaries truly understandable? a large-scale crowdsourced evaluation. Preprint.
- J. Peter Kincaid, Robert P. Jr. Fishburne, Richard L. Rogers, and Brad S. Chissom. 1975. Derivation of new readability formulas (automated readability index, fog count and flesch reading ease) for navy. Technical report, Naval Technical Training Command, Research Branch Report 8-75, Millington, TN, USA.
- Takeshi Kojima, Shixiang Shane Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. 2022. [Large language models are zero-shot reasoners](#). *arXiv preprint arXiv:2205.11916*.
- Jing Li and 1 others. 2024. Large language models for biomedical text simplification: Promising but not there. Preprint.
- G. Harry McLaughlin. 1969. Smog grading—a new readability formula. *Journal of Reading*, 12(8):639–646.
- Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn:

Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.

Gerard Salton and Christopher Buckley. 1988. Term-weighting approaches in automatic text retrieval. *Information Processing and Management*, 24(5):513–523.

Edgar A. Smith and Richard J. Senter. 1967. Automated readability index. Technical Report AMRL-TR-66-220, U.S. Air Force.

Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel R. Bowman. 2019. Glue: A multi-task benchmark and analysis platform for natural language understanding. In *Proceedings of the International Conference on Learning Representations (ICLR)*.

Yuhui Zha, Yusen Yang, Rui Li, and Zhiting Hu. 2023. Alignscore: Evaluating factual consistency with a unified alignment function. *arXiv preprint arXiv:2305.16739*.

Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2020. Bertscore: Evaluating text generation with bert. In *Proceedings of the International Conference on Learning Representations (ICLR)*.

Yuqing Zhang, Hao Liu, Sharan Narang, Yuntao Bai, Ziheng Dai, Adams Wei Yu, Karthik Narasimhan, Jared Kaplan, Pieter Abbeel, Xi Chen, Dawn Song, Alex Wang, Changliu Wang, and Yingbo Tian. 2025. [Moe-1.6t: Efficient large-scale mixture-of-experts training](#). *Preprint*, arXiv:2507.20534.

A. Anexos

A.1. Prompt base

Prompt to translate Cochrane technical abstract into a plain language summary

Using the following abstract of a biomedical study as input, generate a Plain Language Summary (PLS) understandable by any patient, regardless of their health literacy. Ensure that the generated text adheres to the following instructions which should be followed step-by-step:

a. Specific Structure: The generated PLS should be presented in a logical order, using the following order:

1. Plain Title
2. Rationale
3. Trial Design
4. Results

b. Sections should be authored following these parameters:

1. **Plain Title:** Simplified title understandable to a layperson that summarizes the research that was done.
2. **Rationale:** Include background or study rationale providing a general description of the condition, what it may cause or why it is a burden for the patients; the reason and main hypothesis for the study; and why the study is needed and why the study medication has the potential to treat the condition.
3. **Trial Design:** Answer “How is this study designed?” Include the description of the design, description of study and patient population (age, health condition, gender), and the expected amount of time a person will be in the study.
4. **Results:** Answer “What were the main results of the study?” Include the benefits for the patients, how the study was relevant for the area of study, and the conclusions from the investigator.

c. Consistency and Replicability: The generated PLS should be consistent regardless of the order of sentences or the specific phrasing used in the input protocol text.

d. Compliance with Plain Language Guidelines: The generated PLS must follow all these plain language guidelines:

- Have readability grade level of 6 or below.
- Do not have jargon. All technical or medical words or terms should be defined or broken down into simple and logical explanations.
- Use active voice, not passive.
- Use mostly one- or two-syllable words.
- Sentences of 15 words or less.
- Short paragraphs of 3–5 sentences.
- Simple numbers (e.g., ratios, no percentages).

e. Do not invent content: The AI model should not invent information. If the AI model includes data other than the one given in the input abstract, it should guarantee such data is verified and real.

f. Aim for an approximate PLS length of 500–900 words.

A.2. Prompt Optimizado

Using the following biomedical abstract as input, generate a Plain Language Summary (PLS) understandable by any patient, regardless of their health literacy. Ensure that the generated text adheres strictly to the following instructions:

a. **Specific Structure:** The generated PLS must follow exactly this structure:

1. Plain Title
2. Rationale
3. Trial Design
4. Results

b. **Section Requirements:**

- Write short sentences (15 words or fewer).
- Use active voice and simple words.
- Briefly explain any medical term.
- Do not invent information or include content not present in the abstract.

You are a medical writer.
Summarize the following biomedical abstract as a Plain Language Summary (PLS) for any patient.
Use this structure exactly:

1. Plain Title
2. Rationale
3. Trial Design
4. Results

Write short sentences (≤ 15 words) in active voice with simple words.
Explain any medical terms briefly.
Do not invent or assume data not in the abstract.

Abstract: {scientific_text}

PLS:

Plain Title:

Rationale:

Trial Design:

Results:

A.3. Prompt para razonamiento

Using the following biomedical text as input, generate a concise Plain Language Summary (PLS) while performing brief implicit reasoning. The model should think before answering but never reveal its reasoning steps in the output.

a. **Behavioural guidelines:**

- Use only statements explicitly supported by the source text.
- Keep all names, quantities and numeric values exactly as written.
- Produce 4–6 sentences, with a maximum of 120 words in total.
- Do not show the reasoning process in the final answer.

b. **Prompt Template (CoT implícito):**

You are a helpful medical writer.
Think briefly before answering:
- Use only statements explicitly present in the source.
- Keep names and numbers exactly as written.
- 4-6 sentences, ≤ 120 words. Do not show your reasoning.

Scientific text:
{scientific_text}

Plain summary: